Tecnológico de Monterrey

Regresión No Lineal

Análisis comparativo: regresión lineal y no lineal

Analítica de datos y herramientas de inteligencia artificial

2 de noviembre de 2026

Rodrigo Ocampo | A01752337

Introducción

El objetivo es elegir dos modelos de correlación no lineal y analizar la correlación entre las variables numéricas de la base del socio formador, aplicando la herramienta de regresión no lineal (curve_fit de SciPy). Después se comparan los resultados con la regresión lineal simple y múltiple que se hizo en la Actividad 3.

Se usó la misma base que en la regresión lineal: `Ventas_limpio.csv`, con 114,501 líneas de venta de enero de 2023 a septiembre de 2026 de un distribuidor de productos dentales. El código está en `G_Regresion_No_Lineal.ipynb`.

Preparación de los datos

Se tomaron las tres variables numéricas de la base. Igual que en la Actividad 3, se pasaron a rangos ordenados (0 a 4) porque hay valores extremos: un escáner de más de $2 millones contra dientes de $170. Sin los rangos, unos cuantos equipos caros dominarían cualquier curva. Año y mes no se incluyeron porque en la regresión lineal no explicaron casi nada ($R^2 \approx 0.02$).

Variable	Método	Rangos (código 0 a 4)
total_unidades	cut (rangos fijos)	Unitaria (1), Par (2), Pocas (3-5), Mayoreo (6-250)
precio_unitario	qcut (quintiles)	Muy económico, Económico, Medio, Alto, Premium
total_neto	qcut (quintiles)	Mínima, Baja, Media, Alta, Top

Los rangos se codificaron con OrdinalEncoder respetando el orden de negocio.

Elección de variables y modelos

La pareja con mayor correlación es precio unitario (X) y venta total (Y), con r = 0.77. Antes de elegir los modelos se revisó el promedio de la venta total en cada nivel de precio. Si la relación fuera lineal, el promedio subiría siempre lo mismo de un nivel a otro.

Precio unitario	Promedio venta total (Y)	Cambio vs nivel anterior
Muy económico	0.98	—
Económico	0.65	−0.33
Medio	1.76	+1.11
Alto	3.00	+1.24
Premium	3.69	+0.70

El promedio no sube de forma pareja: baja entre Muy económico y Económico, y luego sube más fuerte. Los productos más baratos (fresas, dientes) se compran por volumen, así que su total termina siendo más alto que el de los Económicos, que se venden sueltos. Una recta no puede seguir esa forma; una curva sí.

De la lista de funciones vista en clase se eligieron dos modelos:

Modelo	Ecuación	Por qué se eligió
1. Cuadrático	$y = a \cdot x^2 + b \cdot x + c$	Puede bajar y luego subir, como el promedio real.
2. Exponencial	$y = a \cdot e^{(-b \cdot x)} + c$	Representa un crecimiento que se acelera conforme sube el precio.
Referencia: lineal	$y = b0 + b1 \cdot x$	El modelo de la Actividad 3, para comparar.

En el modelo exponencial se le dio a curve_fit un punto de partida (p0). Sin él, la búsqueda empieza en a = 1, b = 1, c = 1, se "atora" y termina en algo casi igual a una recta ($R^2 = 0.593$).

Resultados: precio unitario → venta total

Modelo	Ecuación obtenida	R^2	R
Lineal (referencia)	$y = 0.45 + 0.78x$	0.593	0.770
Cuadrático	$y = 0.16x^2 + 0.14x + 0.76$	0.628	0.792
Exponencial	$y = 1.29 \cdot e^{(0.31x)} - 0.63$	0.619	0.787

- Cuadrático: el coeficiente a es positivo (0.16), así que la curva se abre hacia arriba. En los precios bajos la venta total casi no cambia y en los altos sube cada vez más rápido.
- Exponencial: b salió negativo (−0.31), por eso el exponente queda positivo y la curva crece. Pero una exponencial siempre sube, así que no puede bajar en el nivel Económico.
- Los dos modelos no lineales superan a la recta. El cuadrático explica 3.4 puntos más (62.8% contra 59.3%).

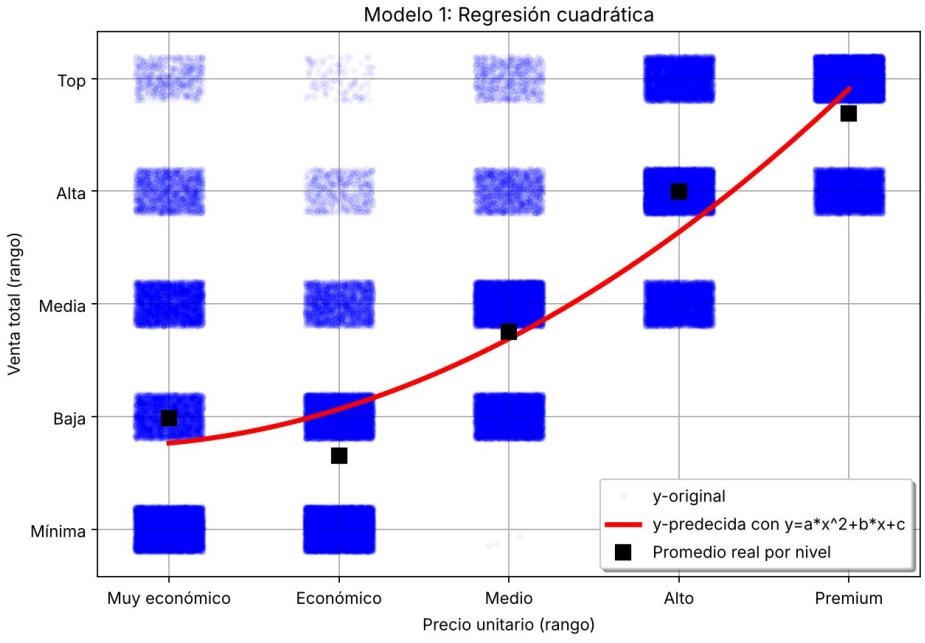


Figura 1. Modelo cuadrático sobre las ventas (puntos con jitter para que no se encimen)

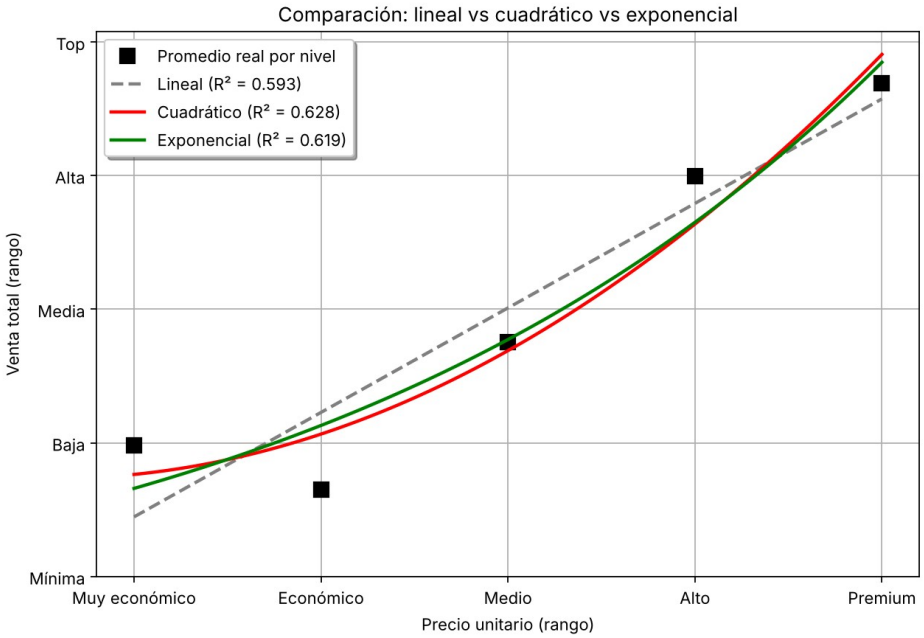


Figura 2. Comparación de las tres curvas contra el promedio real de cada nivel

Tabla de coeficientes de todas las correlaciones

Se aplicaron los tres modelos a las 6 combinaciones posibles entre las tres variables. El orden importa: predecir la venta total con el precio no es lo mismo que predecir el precio con la venta total. La r es la correlación de Pearson del heatmap (con signo). R = √R² es el coeficiente de correlación de cada modelo; en los no lineales no tiene signo.

Pareja (X → Y)	r	R^2 lineal	R lineal	R^2 cuadr.	R cuadr.	R^2 expon.	R expon.
Precio → Venta total	0.770	0.593	0.770	0.628	0.792	0.619	0.787
Unidades → Venta total	0.338	0.114	0.338	0.118	0.344	0.118	0.344
Venta total → Precio	0.770	0.593	0.770	0.595	0.772	0.595	0.771
Venta total → Unidades	0.338	0.114	0.338	0.114	0.338	0.114	0.338
Precio → Unidades	−0.192	0.037	0.192	0.069	0.263	0.097	0.312
Unidades → Precio	−0.192	0.037	0.192	0.045	0.211	0.044	0.211



Figura 3. R^2 por pareja y modelo

- Solo la pareja precio ↔ venta total tiene una relación fuerte (R^2 de 0.59 a 0.63). Las demás quedan por debajo de 0.12 con cualquier modelo.
- Los modelos no lineales siempre igualan o superan al lineal. Entre ellos quedan casi empatados; el cuadrático gana en las dos parejas fuertes.
- La mayor mejora relativa está en precio → unidades: de 0.037 a 0.097 con la exponencial. Sigue siendo débil, pero muestra que el cambio está en un solo punto: los productos Muy económicos se compran en más unidades y a partir de ahí las unidades casi no cambian.
- En el modelo lineal da igual el orden ($R^2 = r^2$). En las curvas no: precio → total da 0.628 y total → precio da 0.595.

Reporte comparativo de los análisis realizados

La siguiente tabla junta los modelos para explicar la venta total en la Actividad 3 (regresión lineal) y en esta actividad (regresión no lineal).

Análisis	Variables (X)	R^2	Qué aporta
Lineal simple	Precio unitario	0.593	Punto de partida: el precio explica cerca del 60%.
No lineal: exponencial	Precio unitario	0.619	Capta que el total crece más rápido en precios altos.
No lineal: cuadrático	Precio unitario	0.628	Mejor modelo de una sola variable.
Lineal múltiple	Precio unitario y unidades	0.837	Mejor modelo en general.

Aspecto	Regresión lineal	Regresión no lineal
Forma de la relación	Recta: Y cambia siempre lo mismo por cada nivel de X.	Curva: el cambio puede acelerarse, frenarse o cambiar de dirección.

Aspecto	Regresión lineal	Regresión no lineal
Herramienta	LinearRegression (sklearn)	curve_fit (SciPy) con la ecuación que uno elige
Interpretación	Directa: b1 = cuánto sube Y por cada nivel de X.	Depende de la ecuación; se explica mejor con la gráfica.
Riesgos	No ve curvas.	Necesita un buen punto de partida (p0); si no, puede terminar en una recta.
Resultado en esta base	R^2 = 0.593 (simple) y 0.837 (múltiple)	R^2 = 0.628 (cuadrático) y 0.619 (exponencial)

Pasar de una recta a una curva mejoró el modelo 3.4 puntos. Agregar las unidades en la regresión múltiple lo mejoró 24 puntos. Para esta base, lo que más mejora un modelo es agregar la variable que falta, más que cambiar la forma de la ecuación. Tiene lógica de negocio: la venta total es precio × unidades, así que con el precio solo se tiene la mitad de la "receta".

Conclusiones

1. La relación entre precio unitario y venta total no es una recta. Los dos modelos no lineales la explican mejor que el lineal, y el mejor es el cuadrático: $y = 0.16x^2 + 0.14x + 0.76$, con $R^2 = 0.628$ y $R = 0.792$.
2. La curva tiene una explicación de negocio. Hay dos tipos de venta: consumibles baratos que se compran por volumen (por eso los Muy económicos tienen un total más alto que los Económicos) y equipo caro que se vende de uno en uno pero cae directo en el rango Top.
3. Las relaciones débiles siguen siendo débiles con cualquier curva. Unidades contra precio o contra venta total no pasan de $R^2 = 0.12$. Un modelo no lineal no crea una relación donde no la hay.
4. El mejor análisis en general sigue siendo la regresión lineal múltiple ($R^2 = 0.84$). Si se quisiera mejorar más, el siguiente paso sería un modelo no lineal con dos variables (precio y unidades), que junte las dos ideas.

Limitaciones

- X y Y son rangos (0 a 4), no pesos. Los modelos sirven para entender la forma de la relación, no para pronosticar montos exactos.
- Con solo 5 niveles de X, una curva tiene pocos puntos para "doblarse". Con los montos reales se vería mejor la forma, pero habría que tratar primero los valores extremos.
- El resultado de la exponencial depende del punto de partida (p0). Hay que revisar siempre que el R^2 no quede igual al de la recta.